

Weekly Report

Takuma Ono

2026 年 1 月 12 日

1 Progress

- I reconsider how to use ViT for Semantic Communication.
- I decided on the paper title: "Uncertainty-Aware Retransmission for Semantic Communication Based on DiffCom"

2 System Model

本セクションでは、不確実性と意味的ガイダンスに基づく画像再送システム (DiffCom with Semantic Retransmission) の全体像について述べる。提案システムは、オリジナルの DiffCom フレームワーク [1] を拡張し、受信側での事後確率サンプリングの結果から「復元の不確実性 (Reconstruction Uncertainty)」と「意味的重要性 (Semantic Importance)」を評価し、動的に再送制御を行う Two-Phase Protocol を採用している。




図 1: System Model

2.1 送信機とチャネルモデル (Transmitter and Channel Model)

入力画像を $\mathbf{x} \in \mathbb{R}^{C \times H \times W}$ とし、その分布を $p(\mathbf{x})$ とする。ここで C, H, W はそれぞれ画像のチャネル数、縦幅、横幅である。提案手法は、DeepJSCC [2] ベースの学習済みエンコーダ $\mathcal{E}(\cdot)$ を用いて、ソース画像を複素チャネル入力シンボル $\mathbf{z} = \mathcal{E}(\mathbf{x}) \in \mathbb{C}^k$ にマッピングする。通信路としては、OFDM 伝送およびフェージング、加法的白色ガウス雑音 (AWGN) を含む物理層の劣化過程を考慮し、これらをチャネル $\mathcal{W}_{h^*}(\cdot)$ とする。ここで h^* は真のチャネル応答を表す。

本システムでは、以下の 2 フェーズ構成による伝送を行う。

2.1.1 Phase 1: Initial Transmission

第 1 フェーズでは、帯域幅制約 (Bandwidth Ratio: ρ) の下で全体像を伝送する。送信信号 $\mathbf{z}$ はチャネル $\mathcal{W}_{h^*}$ を通過し、受信信号 $\mathbf{y}^{(1)}$ は以下のように定式化される。

$$\mathbf{y}^{(1)} = \mathcal{W}_{h^*}(\mathcal{E}(\mathbf{x})) + \mathbf{n}^{(1)}, \quad (1)$$

ここで、 $\mathbf{n}^{(1)} \sim \mathcal{CN}(0, \sigma_{n,1}^2 \mathbf{I}_k)$ は Phase 1 における雑音であり、この時のチャネル SNR (CSNR) を SNR_1 とする。受信機はこの $\mathbf{y}^{(1)}$ を用いて初期復元を行い、後述する再送マスク $\mathbf{M} \in \{0, 1\}^k$ を生成して送信機へフィードバックする。

2.1.2 Phase 2: Semantic Retransmission

第 2 フェーズでは、受信側から要求された「不確実性が高く、かつ意味的に重要な領域」に対応する潜在表現のみを選択的に再送する。再送マスク $\mathbf{M}$ に基づき、送信機は選択された特徴量 $\mathbf{z}_{\text{re}} = \mathbf{M} \odot \mathcal{E}(\mathbf{x})$ を送信する。再送信号は、より高い信頼性 (高い電力割り当てまたは符号化利得) で伝送されると仮定し、受信信号 $\mathbf{y}^{(2)}$ は以下のように表される。

$$\mathbf{y}^{(2)} = \mathbf{M} \odot \left(\mathcal{W}_{h^*}(\mathcal{E}(\mathbf{x})) + \mathbf{n}^{(2)} \right), \quad (2)$$

ここで $\odot$ は要素ごとの積を表し、 $\mathbf{n}^{(2)} \sim \mathcal{CN}(0, \sigma_{n,2}^2 \mathbf{I}_k)$ は Phase 2 の雑音である。再送時は高品質な受信を保証するため、 $\text{SNR}_2 \gg \text{SNR}_1$ (例えば $\text{SNR}_2 = 20 \text{ dB}$) となるように設定される。

最終的に受信機は Phase 1 の初期復元としての $\mathbf{y}^{(1)}$ と、拡散モデルが生成の過程で生じた不確実性と画像の重要領域 (Retransmission) を組み合わせた $\mathbf{y}^{(2)}$ を統合したハイブリッドな観測情報 $\mathcal{Y} = \{\mathbf{y}^{(1)}, \mathbf{y}^{(2)}, \mathbf{M}\}$ を用いて、拡散モデルによる事後確率サンプリング $p_\theta(\mathbf{x} | \mathcal{Y})$ を実行する。

3 各ステップの詳細

3.1 摂動に基づく不確実性推定 (Perturbation-based Uncertainty Estimation)

受信機は、Phase 1 の復元プロセスにおいて、拡散モデルを用いた事後確率サンプリングを実行する際、各タイムステップ t におけるピクセル単位の不確実性マップ $\mathbf{U}_t \in \mathbb{R}^{H \times W}$ を推定する。本稿では、De Vita ら [8] によって提案された、スコア関数の感度 (Sensitivity) に基づく Aleatoric 不確実性の推定手法を採用する。この手法は、同一のデノイズステップに対して入力に微小な摂動を与えた際のスコア関数の出力分散を計算するものであり、追加の学習や外部モデルを必要としない完全な Training-free なアプローチである。

理論的背景として、このスコア関数の分散は、データ分布の対数尤度の二階微分 (Hessian) のトレースと関連していることが示されている [8]。すなわち、入力の微小な変化に対してスコア (勾配) が大きく変動する領域は、確率密度関数の曲率 (Curvature) が大きいことを意味し、モデルがその領域の復元において不安定、あるいは確信度が低い状態にあると解釈できる。

具体的な推定手順は以下の通りである。まず、タイムステップ t における中間潜像 $\mathbf{x}_t$ に対し、現在のスコア推定値 $\epsilon_\theta(\mathbf{x}_t, t)$ を用いて、無雑音データ $\mathbf{x}_0$ の近似値 $\hat{\mathbf{x}}_{0|t}$ を DDIM の定式化 [3] に従って推定する。

$$\hat{\mathbf{x}}_{0|t} = \frac{\mathbf{x}_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_\theta(\mathbf{x}_t, t)}{\sqrt{\bar{\alpha}_t}}, \quad (3)$$

ここで、 $\bar{\alpha}_t$ は拡散過程におけるノイズスケールパラメータである。

次に、この推定された $\hat{\mathbf{x}}_{0|t}$ を起点として、 N 個の独立した摂動サンプル $\{\hat{\mathbf{x}}_t^i\}_{i=1}^N$ を生成する。これらは、拡散過程の前方プロセス (noising process) に従って再度ノイズを付加することで得られる。

$$\hat{\mathbf{x}}_t^i = \sqrt{\bar{\alpha}_t} \hat{\mathbf{x}}_{0|t} + \sqrt{1 - \bar{\alpha}_t} \epsilon^i, \quad \epsilon^i \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \quad (4)$$

最後に、生成された各摂動サンプルに対して拡散モデルのスコア関数を適用し、その出力の分散を計算することで、タイムステップ t における不確実性マップ $\mathbf{U}_t$ を得る。

$$\mathbf{U}_t = \frac{1}{N} \sum_{i=1}^N (\epsilon_\theta(\hat{\mathbf{x}}_t^i, t) - \bar{\epsilon}_t)^2, \quad (5)$$

ここで、 $\bar{\epsilon}_t = \frac{1}{N} \sum_{i=1}^N \epsilon_\theta(\hat{\mathbf{x}}_t^i, t)$ はスコアの平均ベクトルである。算出された $\mathbf{U}_t$ の値が大きい領域は、モデルが局所的な構造に対して高い感度 (Sensitivity) を示しており、復元結果が確率的なノイズの影響を受けやすい不安定な領域であることを示唆する。

さらに、この $\mathbf{U}_t$ は特定のタイムステップ t における瞬時的な不確実性であるため、Phase 1 の復元プロセス全体を通した大域的な不確実性マップ $\bar{\mathbf{U}} \in \mathbb{R}^{H \times W}$ を得るために、時間方向およびチャンネル方向の平均化を行う。計算コストを考慮し、不確実性の評価を行うタイムステップの集合を $\mathcal{T}_{\text{eval}} \subset \{1, \dots, T\}$ とすると、最終的な不確実性マップは以下のように算出される。

$$\bar{\mathbf{U}} = \frac{1}{|\mathcal{T}_{\text{eval}}|} \sum_{t \in \mathcal{T}_{\text{eval}}} \left(\frac{1}{C} \sum_{c=1}^C \mathbf{U}_{t,c} \right), \quad (6)$$

ここで、 C はチャンネル数、 $\mathbf{U}_{t,c}$ はタイムステップ t におけるチャンネル c の不確実性マップを表す。

3.2 セマンティック重要度マップの抽出 (Semantic Importance Extraction)

再送リソースを視覚的・意味的に重要な領域へ重点的に配分するため、本システムでは事前学習済みの Vision Transformer (ViT) を用いた重要度抽出を行う。具体的には、自己教師あり学習モデルである DINOv3 [7] を採用する。Phase 1 で得られた初期復元画像 $\hat{\mathbf{x}}^{(1)}$ を ViT に入力し、最終層の Multi-Head Self-Attention (MHSA) マップを取得する。[CLS] トークンに対する各パッチのアテンション重みを集約し、空間的に補間することで、画素単位の意味的重要性マップ $\mathbf{V} \in [0, 1]^{H \times W}$ を生成する。この $\mathbf{V}$ は、画像内の主要なオブジェクトや構造的に重要な領域において高い値を示し、不確実性マップ $\bar{\mathbf{U}}$ と共に再送領域の決定に利用される。

3.3 不確実性マスクとセマンティック重要度マップの統合 (Mask Combination)

提案法では、受信機側で推定された不確実性マップ $\mathbf{U}$ と意味的重要性マップ $\mathbf{V}$ を統合し、動的に再送マスク $\mathbf{M}$ を生成する。まず、画像空間上のマップ $\mathbf{U}, \mathbf{V}$ を潜在空間の次元 $H_z \times W_z$ に合わせるため、平均プーリングによりダウンサンプリングを行い、 $\mathbf{U}_{\text{lat}}, \mathbf{V}_{\text{lat}}$ を得る。ここで、全潜在画素数を $N = H_z \times W_z$ 、目標とする再送率 (Budget Rate) を $R \in (0, 1]$ とする。

再送マスクの決定プロセスは以下の手順で行われる。

1. **候補領域の抽出 (Candidate Generation):** まず、受信側で再送候補の探索範囲を決定するための係数を $\eta \geq 1$ (Expansion Factor) とする。不確実性マップ $\mathbf{U}_{\text{lat}}$ の値が高い順に上位 $K_{\text{cand}} = \lfloor N \cdot R \cdot \eta \rfloor$ 個の画素インデックスを選択し、これを候補集合 $\mathcal{S}_{\text{cand}}$ とする。これにより、不確実性が低い領域をあらかじめ除外する。受信側はこの $\mathcal{S}_{\text{cand}}$ だけを送信側にフィードバックすることで実現可能性を高めている。

2. **予算の配分 (Budget Allocation):** 実際に再送可能な画素数（総予算）は $K_{\text{total}} = \lfloor N \cdot R \rfloor$ である。送信側はこれを意味的優先枠の比率 $\gamma \in [0, 1]$ に基づき、以下のように分割する。

- 意味的予算: $K_{\text{sem}} = \lfloor K_{\text{total}} \cdot \gamma \rfloor$
- 構造的（ランダム）予算: $K_{\text{rnd}} = K_{\text{total}} - K_{\text{sem}}$

3. **ハイブリッド選択 (Hybrid Selection):** 候補集合 $\mathcal{S}_{\text{cand}}$ の中から、最終的な再送画素を以下の2段階で決定する。

- **Step 1 (Semantic):** $\mathcal{S}_{\text{cand}}$ 内の画素に対応する意味的重要性マップ $\mathbf{V}_{\text{lat}}$ の値を参照し、値が高い順に K_{sem} 個を選択する。
- **Step 2 (Structural):** $\mathcal{S}_{\text{cand}}$ のうち Step 1 で選択されなかった残りの画素から、 K_{rnd} 個を一様ランダムに選択する。これは、意味的重要性は低いが復元難易度が高い（不確実性が高い）テキスト情報の欠落を防ぐ役割を果たす。

最終的に選択されたインデックスに対応するマスク $\mathbf{M}$ の要素を 1、それ以外を 0 とし、再送信号を電力を高く割り当てるなどして高品質なチャンネルで送信する。

3.4 整合性損失による事後確率サンプリング (Consistency-Guided Posterior Sampling)

Phase 2 の復号プロセスでは、拡散モデルの逆拡散過程において、受信したハイブリッド観測情報 $\mathcal{Y} = \{\mathbf{y}^{(1)}, \mathbf{y}^{(2)}, \mathbf{M}\}$ との整合性を保つようにサンプリングをガイドする。タイムステップ t における推定画像 $\hat{\mathbf{x}}_{0|t}$ に対し、以下の整合性損失（Consistency Loss）勾配を用いてスコア関数を修正する。

$$\nabla_{\mathbf{x}_t} \mathcal{L} = \nabla_{\mathbf{x}_t} \left(\left\| (\mathbf{1} - \mathbf{M}) \odot (\mathbf{y}^{(1)} - \mathcal{W}_{h^*}(\mathcal{E}(\hat{\mathbf{x}}_{0|t}))) \right\|_2^2 + \left\| \mathbf{M} \odot (\mathbf{y}^{(2)} - \mathcal{W}_{h^*}(\mathcal{E}(\hat{\mathbf{x}}_{0|t}))) \right\|_2^2 \right) \quad (7)$$

第1項は、再送されなかった領域 $(\mathbf{1} - \mathbf{M})$ において、Phase 1 の受信信号 $\mathbf{y}^{(1)}$ との整合性を維持する。第2項は、再送領域 $(\mathbf{M})$ において、高品質な再送信号 $\mathbf{y}^{(2)}$ との整合性を強く強制する。ここで $\mathcal{E}(\cdot)$ は決定論的なエンコーダであり、 $\mathcal{W}_{h^*}$ はチャンネルモデル（フェージングおよびノイズ付加）を表す。本手法では、再送信号 $\mathbf{y}^{(2)}$ についても推定画像をエンコード後にチャンネルシミュレーション $\mathcal{W}_{h^*}$ を通過させ、受信信号領域での整合性を評価する。この分割された損失により、高 SNR で再送された情報を DeepJSCC で情報を落とすことなく再送できる。

4 実験設定

4.1 データセットおよびモデル

本実験では、提案手法の汎用性と有効性を検証するために、異なる特性を持つ2つのデータセットを使用した。一つは人間の顔画像に特化した **FFHQ** (Flickr-Faces-HQ, 256×256) [9], もう一つは多様な物体や風景を含む **ImageNet** (256×256) [10] である。拡散モデルのバックボーンには、ImageNet に対しては '256x256_diffusion_uncond', FFHQ に対しては 'ffhq_10m' の学習済みモデルを採用した。またエンコーダには DeepJSCC (DJSCC) を使用した。

4.2 ベースライン

比較手法は以下の3つである。

- **Random Baseline:** 再送する場所を再送率をみたすようにランダムに再送する手法
- **Perturbation (Unc):** 再送する場所を不確実性のみを基準に決定する提案手法
- **Perturbation (Sem):** 再送する場所を不確実性と意味的重要性の両方を考慮して決定する提案手法

4.3 通信チャネルモデル

送信信号は加法的白色ガウス雑音 (AWGN) チャネルを通して伝送されるものとした。チャネル信号対雑音比 (CSNR) は、低 SNR 環境下での性能を詳細に評価するため、-8 dB から 0 dB の範囲で変動させて実験を行った。再送フェーズ (Phase 2) における信号は、高品質な伝送を模擬するため、十分に高い SNR (20 dB) を仮定してエンコードされた。

4.4 提案手法の設定 (HPRS)

提案する Hybrid-Priority Retransmission Simulation (HPRS) では、不確実性と意味的重要度の双方を利用して再送マスクを決定する。

- **不確実性推定:** 拡散モデルの生成過程における摂動分散 (Perturbation Uncertainty) を利用した。

- **意味的抽出:** 画像内の意味的に重要な領域を特定するために、事前学習済みの Vision Transformer である **DINOv3** ('facebook/dinov3-vitb16-pretrain-lvd1689m') [7] の Attention マップを使用した。
- **再送パラメータ:** 再送率 (Retransmission Rate) は全画素の 10% (0.1) を基準とし、候補領域の探索範囲を決定する拡大係数 (Expansion Factor) は 2.0 に設定した。再送予算の配分比率 γ は、意味的優先枠と構造的ランダム枠のバランスを調整するものであり、デフォルトで 0.3 または 0.7 として評価を行った。

4.5 評価指標

再構成画像の品質評価には、以下の客観的および知覚的指標を用いた。

- **PSNR (Peak Signal-to-Noise Ratio):** ピクセルレベルの信号忠実度を評価する。
- **LPIPS (Learned Perceptual Image Patch Similarity):** 人間の視覚特性に近い知覚的類似性を評価する。[4]
- **DISTS (Deep Image Structure and Texture Similarity):** 画像の構造とテクスチャの両方の観点から知覚的な類似度を評価し、細部のパターンの整合性を測定する。[5]
- **FID (Frechet Inception Distance):** 生成画像の分布と実画像分布の距離を測定し、全体的な画像の自然さを評価する。[6]

5 実験結果

5.1 不確実性の利用の評価

まず、不確実性の利用が再送の基準としてどれだけ有効かを検証した。不確実性マップ U と Phase 1 の再構成誤差マップ E (L1 誤差) の間のピアソン相関係数 r は、画素インデックスを i , それぞれの平均値を $\bar{U}, \bar{E}$ として以下の式で計算される。

$$r = \frac{\sum_i (U_i - \bar{U})(E_i - \bar{E})}{\sqrt{\sum_i (U_i - \bar{U})^2} \sqrt{\sum_i (E_i - \bar{E})^2}} \quad (8)$$

FFHQ データセットおよび ImageNet データセットを用いた実験において、各チャンネル信号対雑音比 (SNR) 条件下で算出された相関係数の平均値をそれぞれ表 1 と表 2 に示す。

表 1: 不確実性と再構成誤差の相関係数 (FFHQ)

SNR (dB)	Correlation
-8.0	0.240
-7.0	0.311
-6.0	0.358
-5.0	0.391
-4.0	0.417
-2.0	0.433

表 2: 不確実性と再構成誤差の相関係数 (ImageNet)

SNR (dB)	Correlation
-8.0	0.240
-7.0	0.329
-6.0	0.383
-5.0	0.421
-4.0	0.438


これらの結果より，SNR が改善するにつれて相関係数は上昇する傾向にあり，不確実性マップと実際の再構成誤差が高い相関を示していることが確認された．これは，不確実性が再送すべき領域を特定するための有効な指標であることを示唆している．。

5.2 メトリック評価


FFHQ データセットに対しては以下の結果を得た

Comparison (ffhq_demo - Rate: 0.1) [Exp:2.0, Gam:0.3]


PSNR



LPIPS



DISTS



FID




図 2: 結果 (FFHQ)

Comparison (imagenet - Rate: 0.1) [Exp:2.0, Gam:0.3]




図 3: 結果 (ImageNet)

定量評価の結果, 全ての評価指標, 特に低 SNR 環境下 (≤ -4 dB) において, 提案手法は比較手法に対し顕著な優位性を示した. とりわけ, DISTS および FID の大幅な改善が確認できる. これは, 不確実性推定によって拡散モデルが生成過程で「確信を持ってない (分散が大きい)」領域, すなわちノイズによる劣化が激しく復元が困難な箇所を的確に特定し, 重点的に再送を行えるためである. 結果として, 拡散モデルは高品質な再送信号をガイドとして利用することで, 生成時の幻覚やアーティファクトを抑制し, より自然で構造的整合性の高い画像を復元できたと考えられる.

5.3 ViT による重要度評価の結果

ここでは ViT による重要な領域の特定が、どの程度復元に効果があるのかを同様に FFHQ と ImageNet データセットを用いて実証する。

5.3.1 FFHQ データセット

FFHQ データセットに対するメトリックには **ID Loss** を用いた。これは正解画像と復元画像の同一人物性 (Identity) を示す指標である。




図 4: ID Loss Comparison ($\gamma = 0.7$)

上の結果から、全ての SNR において Perturbation (Sem) が優位な結果を残した。これはまさしく重要度を考慮する必要性を示している。ViT による重要度評価によって、目や口など顔画像の中でも重要な領域にリソースを集中させることができるため、ID Loss において良好な結果が得られていると考えられる。



图 5: Ground Truth



图 6: Phase 1: 1st Restoration




图 7: ViT Saliency Map (A)




图 8: Mask: Perturbation (Unc)



图 9: Mask: Perturbation (Sem)

图 10: Visualization of initial restoration image, and retransmission masks based on uncertainty and importance.



图 11: Random



图 12: Perturb (Unc)



图 13: Perturb (Sem)

图 14: Comparison of final restoration results ($\text{SNR} = -4\text{dB}$). The proposed methods (middle/right) reduce unnaturalness in eyes and mouth compared to Random (left).

5.3.2 ImageNet データセットによる意味的整合性の評価

本節では、提案手法が再構成画像において画像の意味的特徴（セマンティクス）をどの程度保持できているかを定量的に評価するため、ImageNet データセットを用いた画像分類タスクによる検証を行った。

評価指標の算出には、外部評価器として ImageNet-1K データセットで事前学習された **Swin Transformer V2-B** [11] を採用した。このモデルは ImageNet 検証セットにおいて約 84.1% という高い Top-1 精度を有している。

具体的な評価プロトコルは以下の通りである。まず、送信前の元画像 (Ground Truth) を当該分類モデルに入力し、その出力確率分布から得られる Top-1 予測クラスを、その画像の「意味的正解ラベル」として定義する。続いて、各手法によって伝送・再構成された画像 (受信画像) を同一の分類モデルに入力し、予測されたクラスが元画像の正解ラベルと一致するかを判定した。この一致率を**分類一貫性 (Classification Consistency)** として定義し、セマンティック重要度を考慮した Perturbation (Sem) 手法が、背景ではなく主要な物体を優先的に保護することができているかを評価した。

図 15 に、各 SNR 条件下における分類精度の比較結果を示す。




図 15: ImageNet データセットにおける分類一貫性 (Classification Consistency) の比較。提案手法 (Perturbation (Sem)) は、重要度が高い主要な領域を優先的に再送することで、不確実性のみを用いた手法やランダム選択に比べて、優れた性能を示した。

参考文献

- [1] S. Wang, J. Dai, K. Tan, X. Qin, K. Niu and P. Zhang, "DiffCom: Channel Received Signal Is a Natural Condition to Guide Diffusion Posterior Sampling," in *IEEE Journal on Selected Areas in Communications*, vol. 43, no. 7, pp. 2651-2666, July 2025, doi: 10.1109/JSAC.2025.3559158.
- [2] E. Bourtsoulatz, D. B. Kurka, and D. Gunduz, "Deep joint source-channel coding for wireless image transmission," *IEEE Trans. Cogn. Commun. Netw.*, vol. 5, no. 3, pp. 567-579, Sep. 2019.
- [3] Song, J., Meng, C., Ermon, S.: Denoising diffusion implicit models. In: *International Conference on Learning Representations (2020)* 1, 4, 5, 7
- [4] R. Zhang, P. Isola, A. A. Efros, E. Shechtman, and O. Wang, "The unreasonable effectiveness of deep features as a perceptual metric," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, Jun. 2018, pp. 586 – 595
- [5] K. Ding, K. Ma, S. Wang, and E. P. Simoncelli, "Image quality assessment: Unifying structure and texture similarity," 2020, arXiv:2004.07728.
- [6] M. Heusel, H. Ramsauer, T. Unterthiner, B. Nessler, and S. Hochreiter, "GANs trained by a two time-scale update rule converge to a local Nash equilibrium," in *Proc. Adv. Neural Inf. Process. Syst.*, vol. 30, Jan. 2017, pp. 6629 – 6640.
- [7] O. Siméoni, H. V. Vo, M. Seitzer, F. Baldassarre, M. Oquab, C. Jose, V. Khalidov, M. Szafraniec, S. Yi, M. Ramamonjisoa, F. Massa, D. Haziza, L. Wehrstedt, J. Wang, T. Darcet, T. Moutakanni, L. Sentana, C. Roberts, A. Vedaldi, J. Tolan, J. Brandt, C. Couprie, J. Mairal, H. Jégou, P. Labatut, and P. Bojanowski, "DINOv3," arXiv preprint arXiv:2508.10104, 2025.
- [8] M. De Vita and V. Belagiannis, "Diffusion Model Guided Sampling with Pixel-Wise Aleatoric Uncertainty Estimation," 2025 *IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, Tucson, AZ, USA, 2025, pp. 3844-3854, doi: 10.1109/WACV61041.2025.00378.
- [9] T. Karras, S. Laine, and T. Aila, "A style-based generator architecture for generative adversarial networks," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, Jun. 2019, pp. 4401 – 4410.

- [10] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, “ImageNet: A large-scale hierarchical image database,” in Proc. IEEE Conf. Comput. Vis. Pattern Recognit., Jun. 2009, pp. 248 – 255.
- [11] Z. Liu et al., ”Swin Transformer V2: Scaling Up Capacity and Resolution,” 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), New Orleans, LA, USA, 2022, pp. 11999-12009, doi: 10.1109/CVPR52688.2022.01170.